

Construción de coleccións de adestramento de preguntas-respostas médicas e axuste de modelos de linguaxe de gran tamaño para a resposta fiable a preguntas médicas

Brais Gómez López

Universidade de Santiago de Compostela

Máster Universitario en Tecnoloxías de Análise de Datos Masivos: Big Data

Titores: David Enrique Losada Carril e Márcos Fernández Pichel

Resumo

Os modelos de linguaxe de gran tamaño (LLM) consolidáronse como ferramentas prometedoras para o desenvolvemento de sistemas de resposta automática a preguntas médicas. Non obstante, a súa adaptación ao dominio sanitario continúa dependendo en gran medida da dispoñibilidade de coleccións de adestramento especializadas, cuxa construción require combinar coñecemento médico fiable con datos representativos das consultas formuladas polas persoas usuarias.

Para abordar este problema, neste traballo preséntase unha metodoloxía para a construción de coleccións de preguntas e respostas médicas destinadas ao axuste fino supervisado (*Supervised Fine-Tuning*, SFT) de modelos de linguaxe. A metodoloxía parte da análise comparativa de diferentes fontes de información sanitaria e materialízase na creación de dúas coleccións complementarias: Drugs-SFT, construída a partir de preguntas e respostas reais extraídas da plataforma especializada Drugs.com, e WHO-SFT, xerada automaticamente a partir do contido das fichas informativas da Organización Mundial da Saúde mediante un modelo de linguaxe.

As coleccións obtidas empregáronse para adaptar dous modelos de linguaxe mediante QLoRA, que posteriormente se avaliaron sobre o *benchmark* MIRAGE, composto por varios conxuntos de preguntas médicas. Os resultados mostran que o axuste fino cos corpus construídos non garante unha mellora global uniforme, pero si produce cambios relevantes no comportamento dos modelos. Observáronse melloras en determinados subconxuntos, especialmente en PubMedQA nos experimentos con Gemma 3 4B-IT, ao tempo que se produciron degradacións noutras tarefas. Isto indica que o impacto da especialización depende da natureza do corpus, da súa correspondencia co *benchmark* de avaliación e do modelo base empregado.

Este traballo pon de manifesto que a construción das coleccións de adestramento constitúe un factor central na adaptación de modelos de linguaxe ao dominio médico e proporciona unha metodoloxía reproducible para crear e avaliar novos corpus especializados.

Palabras chave: modelos de linguaxe, pregunta-resposta médica, QLoRA.

1. Introducción

O acceso á información médica fiable constitúe un elemento esencial para a práctica clínica, a formación dos profesionais sanitarios e a toma de decisións por parte dos pacientes. Porén, o crecemento constante da literatura biomédica e a rápida evolución do coñecemento científico dificultan a consulta e integración eficiente da información dispoñible. Neste contexto, a intelixencia artificial e, en particular, os modelos de linguaxe de gran tamaño (*large language models*, LLM) ofrecen novas posibilidades para facilitar o acceso ao coñecemento médico mediante interaccións en linguaxe natural. Os avances acadados nos últimos anos mostran que estes modelos poden ofrecer respostas cada vez máis próximas ás elaboradas por profesionais sanitarios en tarefas de pregunta-resposta médica, abrindo novas vías para o desenvolvemento de asistentes clínicos intelixentes [1, 2].

A pesar deste potencial, o ámbito sanitario continúa representando un dos escenarios máis complexos para a aplicación dos LLM. A necesidade de ofrecer información rigorosa, actualizada e sustentada na evidencia científica fai que pequenas imprecisións poidan traducirse en recomendacións potencialmente perigosas. Ademais, os modelos fundacionais, é dicir, modelos preadestrados a grande escala sobre datos xerais e reutilizables en múltiples tarefas, adoitan ser adestrados con corpus de propósito xeral, nos que o coñecemento biomédico especializado representa só unha parte da información incorporada durante o preadestramento. Como consecuencia, estes sistemas poden producir respostas incompletas, empregar terminoloxía incorrecta ou xerar afirmacións sen respaldo científico, fenómeno coñecido como alucinación, que constitúe un dos principais obstáculos para a súa utilización en contornos clínicos [2–4].

Co obxectivo de reducir estas limitacións, propuxéronse diferentes estratexias, entre as que destacan o axuste fino supervisado (*Supervised Fine-Tuning*, SFT) e os sistemas baseados en xeración aumentada mediante recuperación (*Retrieval-Augmented Generation*, RAG). O SFT adapta o modelo mediante exemplos de instrución e resposta, mentres que RAG recupera información externa relevante e incorpóraa ao contexto utilizado durante a xeración [5, 6]. O rendemento de ambas as aproximacións depende da calidade da información empregada, xa sexa

nos datos utilizados durante o axuste ou nos documentos recuperados durante a xeración [4].

No caso do SFT, as coleccións de adestramento deixan de constituír un simple recurso auxiliar para converterse nun elemento fundamental do proceso de especialización. A diversidade das fontes biomédicas, a heteroxeneidade dos formatos e a necesidade de transformar documentos científicos ou divulgativos en exemplos estruturados de preguntas e respostas converten a construción destes conxuntos de datos nun problema de investigación aberto.

A literatura recente recolle un elevado número de traballos centrados na avaliación de modelos médicos especializados ou na comparación de distintas técnicas de adaptación. Con todo, os procesos empregados para construír as coleccións de adestramento que alimentan estes modelos reciben menos atención. Aspectos como a selección das fontes documentais, a xeración automática de pares pregunta–resposta, os criterios de filtrado ou o impacto destas decisións sobre o comportamento final dos modelos continúan insuficientemente estudados, o que dificulta tanto a reproducibilidade dos experimentos como a comparación entre diferentes propostas.

Para abordar esta problemática, o obxectivo principal desta investigación consiste en deseñar unha metodoloxía reproducible para construír coleccións de preguntas e respostas médicas a partir de diferentes fontes de información biomédica e empregalas para adaptar modelos de linguaxe mediante SFT. Ademais da construción dos conxuntos de datos, analízase a influencia das diferentes coleccións sobre o comportamento e o rendemento dos modelos en tarefas médicas de pregunta–resposta. Neste sentido, unha parte central do traballo é a creación dos propios recursos de adestramento: por unha banda, unha colección baseada en preguntas e respostas reais de Drugs.com e, por outra, unha colección xerada automaticamente a partir do contido das fichas informativas da OMS.

Como principais contribucións, este traballo propón un proceso sistemático para construír coleccións de preguntas e respostas médicas, desenvolve un fluxo de traballo reproducible¹ para adaptar modelos de linguaxe mediante estas coleccións e realiza unha avaliación comparativa do efecto que diferentes fontes de coñecemento exercen sobre o seu rendemento. Deste modo, a investigación non se limita á adaptación dun modelo concreto, senón que considera as coleccións creadas como recursos reutilizables e analiza o papel dos datos como un elemento central na especialización de modelos de linguaxe para tarefas médicas de pregunta–resposta.

2. Traballos relacionados

2.1. Resposta a preguntas médicas (*Medical Question Answering*)

A resposta automática a preguntas médicas (*Medical Question Answering*, Medical QA) converteuse nun dos principais escenarios para avaliar a capacidade dos modelos de linguaxe no ámbito sanitario. O seu obxectivo

consiste en responder consultas médicas formuladas en linguaxe natural empregando coñecemento biomédico especializado. Para medir o rendemento destes sistemas desenvóléronse diferentes *benchmarks*, entre os que destacan PubMedQA, construído a partir da literatura científica publicada en PubMed [7]; MedQA, baseado en preguntas de exames médicos de licenza [8]; e MedMCQA, formado por preguntas procedentes de exames médicos reais [9].

A dispoñibilidade destes *benchmarks* impulsou o desenvolvemento de modelos médicos especializados baseados en LLM. Entre estes modelos destacan Med-PaLM e Med-PaLM 2, que demostraron que a adaptación de modelos fundacionais ao dominio biomédico permite mellorar significativamente a capacidade para responder preguntas médicas e aproximar o seu rendemento ao de profesionais sanitarios en determinados *benchmarks* [2, 10]. Non obstante, a maior parte destes traballos céntrase na avaliación dos modelos empregando coleccións de datos xa existentes, mentres que a construción das coleccións de adestramento necesarias para especializar estes sistemas continúa recibindo unha atención considerablemente menor. Esta limitación motiva a necesidade de investigar metodoloxías que permitan construír coleccións de preguntas e respostas de alta calidade a partir de diferentes fontes de información biomédica.

2.2. Construción de coleccións de preguntas e respostas médicas

A dispoñibilidade de coleccións de preguntas e respostas constitúe un dos elementos fundamentais para a adaptación e avaliación de modelos de linguaxe no dominio biomédico. Tradicionalmente, estes conxuntos de datos foron elaborados de maneira manual por expertos/as ou derivados de exames médicos, literatura científica e documentación clínica. Estes procedementos requiren unha curación coidadosa dos datos, o que pode limitar o seu tamaño e a facilidade para incorporar novo coñecemento [7–9].

Estas coleccións poden obterse mediante diferentes estratexias, desde a anotación manual realizada por expertos/as ata a transformación automática de documentación biomédica empregando modelos de linguaxe.

O desenvolvemento dos LLM impulsou novas metodoloxías orientadas á xeración automática de coleccións de adestramento. Diversos traballos propoñen empregar modelos de linguaxe para transformar documentos biomédicos en pares de preguntas e respostas ou en instrucións destinadas ao SFT, reducindo significativamente o esforzo manual necesario para construír novos corpus [5]. Estas aproximacións permiten ampliar rapidamente o volume de datos dispoñible e adaptar os modelos a especialidades médicas concretas.

Non obstante, a xeración automática de coleccións introduce novos desafíos relacionados coa calidade dos datos. A selección das fontes documentais, a formulación das preguntas, a fidelidade das respostas respecto á información orixinal, a eliminación de duplicados ou os procesos de filtrado e validación poden condicionar o comportamento do modelo durante o adestramento. A literatura destaca que, ademais do volume, a calidade das

¹Repositorio de código e recursos do proxecto.

coleccións e os procesos sistemáticos de validación son relevantes e contribúen á fiabilidade dos datos empregados no *fine-tuning* [4].

2.3. Adaptación de modelos de linguaxe ao dominio biomédico

Os modelos de linguaxe de gran tamaño (*large language models*, LLM) demostraron unha notable capacidade para resolver tarefas de comprensión e xeración de texto en múltiples dominios [11–13]. Porén, ao seren adestrados principalmente sobre corpus de propósito xeral, presentan limitacións cando se aplican ao ámbito biomédico, onde a terminoloxía especializada, a complexidade dos conceptos clínicos e a constante evolución do coñecemento científico requiren un maior grao de especialización [1].

Co obxectivo de superar estas limitacións desenvóléronse diferentes estratexias para adaptar modelos de linguaxe ao dominio médico. Os primeiros traballos centráronse en continuar o preadestramento de modelos existentes empregando literatura biomédica, dando lugar a propostas como BioBERT e PubMedBERT, que demostraron melloras significativas en tarefas clásicas de procesamento da linguaxe biomédica [14, 15]. Máis recentemente, modelos biomédicos como BioMistral demostraron que estas estratexias tamén poden aplicarse con éxito aos LLM, mellorando o seu comportamento en tarefas biomédicas especializadas [16].

Unha vez dispoñibles coleccións de adestramento adecuadas, a especialización dos modelos pode realizarse mediante diferentes técnicas de adaptación. Entre elas, o SFT consolidouse como unha das aproximacións máis empregadas para especializar ou modificar o comportamento de modelos fundacionais mediante pares de instrución e resposta elaborados para un dominio concreto [4, 5].

Nos últimos anos apareceron diferentes variantes orientadas a reducir o custo computacional do proceso de adaptación. Técnicas como LoRA (*Low-Rank Adaptation*) e QLoRA permiten axustar modelos de gran tamaño modificando un número reducido de parámetros, conseguindo resultados comparables ao *fine-tuning* tradicional cun consumo significativamente menor de memoria e recursos computacionais [17, 18]. Estas aproximacións favoreceron a aparición dun elevado número de modelos especializados en dominios concretos, entre eles o ámbito biomédico.

Estes traballos poñen de manifesto que o rendemento dun modelo especializado non depende unicamente da arquitectura empregada, senón tamén da información utilizada durante o proceso de adaptación. En consecuencia, a construción de coleccións de datos que poden contribuir á especialización biomédica dos modelos constitúe un elemento relevante na especialización de modelos de linguaxe [1, 4].

2.4. Posicionamento deste traballo

Os traballos revisados ao longo desta sección evidencian o rápido avance experimentado polos sistemas de resposta a preguntas médicas e polos modelos de linguaxe aplicados ao dominio biomédico. A aparición de

benchmarks de referencia, a construción de coleccións de adestramento e a consolidación de técnicas de adaptación como o SFT permitiron mellorar notablemente a capacidade destes sistemas para responder preguntas médicas.

Con todo, a maior parte das investigacións céntrase na comparación de modelos ou técnicas de adaptación, mentres que o proceso de construción das coleccións de adestramento recibe unha atención considerablemente menor. Aspectos como a selección das fontes biomédicas, a xeración de pares de preguntas-respostas, os procesos de limpeza e validación ou a influencia da calidade dos datos sobre o comportamento final do modelo continúan insuficientemente explorados.

Para abordar esta problemática, o obxectivo principal desta investigación consiste en deseñar unha metodoloxía reproducible para a construción de coleccións de preguntas-respostas médicas a partir de diferentes fontes de información biomédica, empregándoas posteriormente para adaptar modelos de linguaxe mediante técnicas de SFT e analizar a influencia que estas coleccións exercen sobre a fiabilidade das respostas xeradas.

3. Metodoloxía

3.1. Visión xeral da metodoloxía

O obxectivo principal desta investigación consiste na construción de coleccións de adestramento de preguntas-respostas médicas para a adaptación de modelos de linguaxe de gran tamaño mediante técnicas de SFT. Para iso deseñouse unha metodoloxía estruturada en varias fases que abrangue desde a selección das fontes de información ata a avaliación dos modelos resultantes.

A Figura 1 resume o fluxo completo da metodoloxía deste traballo.




Figura 1: Fluxo xeral da metodoloxía proposta para a construción das coleccións de adestramento e avaliación dos modelos adaptados.

3.2. Selección das fontes de información

A construción de coleccións de adestramento de alta calidade require partir de fontes de información que proporcionen contido fiable, estruturado e representativo do dominio obxecto de estudo. No ámbito sanitario, a dispoñibilidade de información na Web é moi ampla; con todo, a súa calidade, nivel de revisión e formato presentan diferenzas significativas. Por este motivo, antes de iniciar o proceso de construción das coleccións realizouse unha análise comparativa de diferentes plataformas co obxectivo de identificar aquelas máis adecuadas para os obxectivos deste traballo.

Para esta análise definíronse diferentes criterios de comparación, entre eles o tipo de plataforma, a fiabilidade da información, o perfil dos autores das respostas, a estrutura do contido e o volume potencial de información dispoñible para a súa extracción. Estes criterios permitiron avaliar tanto a calidade do coñecemento ofrecido por cada fonte como a súa idoneidade para a construción automática de coleccións de preguntas-respostas. A Táboa 1 resume os criterios empregados nesta análise.

Táboa 1: Criterios empregados na análise das fontes de información médica.

Criterio	Descrición
Tipo de plataforma	Foro, plataforma QA, comunidade, fonte institucional.
Fiabilidade	Nivel de revisión e respaldo científico.
Autor das respostas	Profesionais, pacientes, usuarios/as anónimos/as.
Estrutura	Pregunta-resposta, artigos, fíos de discusión.
Volume	Cantidade potencial de información extraíble.

A Táboa 2 resume a clasificación realizada sobre as principais plataformas analizadas. As fontes estudadas inclúen comunidades de pacientes, plataformas de consulta médica, foros especializados e páxinas institucionais con información sanitaria revisada. Esta análise puxo de manifesto que ningunha das plataformas reunía simultaneamente un elevado nivel de fiabilidade e unha gran dispoñibilidade de pares de preguntas-respostas, polo que se optou por seleccionar dúas fontes con características complementarias.

Por unha banda, a páxina de respostas do sitio Drugs.com² foi seleccionada por dispoñer dun amplo conxunto de preguntas formuladas por usuarios/as acompañadas de respostas elaboradas ou revisadas por profesionais sanitarios. Esta característica permitía obter un corpus formado por interaccións reais entre usuarios/as e expertos/as, mantendo ao mesmo tempo un nivel de fiabilidade superior ao doutras comunidades abertas ou foros de discusión.

Por outra banda, seleccionáronse as fichas descritivas de enfermidades da OMS (en inglés, *WHO Fact Sheets*)³. A diferenza da páxina de respostas de Drugs.com, esta fonte non ofrece pares de preguntas-respostas de manei-

ra explícita, senón documentos informativos elaborados por un organismo internacional de referencia. A elevada fiabilidade do seu contido e a súa estrutura homoxénea motivaron a utilización desta fonte para explorar unha segunda estratexia baseada na xeración automática de preguntas-respostas a partir de documentación médica contrastada.

Deste modo, este traballo combina dúas aproximacións complementarias para a construción de coleccións de adestramento: a reutilización de preguntas-respostas reais procedentes dunha plataforma especializada e a xeración automática de novas preguntas-respostas a partir dunha fonte institucional de elevada calidade. Esta combinación permite analizar o impacto que diferentes tipos de coleccións exercen sobre o proceso de adaptación dos modelos de linguaxe.

Unha vez seleccionadas as dúas fontes, desenvóléronse dúas metodoloxías independentes para a construción das coleccións de adestramento, adaptadas ás características específicas de cada plataforma.

3.3. Construción da colección Drugs-SFT

A colección Drugs-SFT construíuse a partir da páxina de respostas de Drugs.com, que ofrece unha estrutura de preguntas e respostas elaboradas arredor de consultas formuladas por usuarios/as sobre medicamentos, enfermidades e tratamentos. A principal vantaxe desta fonte reside en que as respostas son elaboradas ou revisadas por profesionais sanitarios, permitindo obter un corpus baseado en interaccións reais cun nivel de fiabilidade superior ao doutras comunidades abertas.

A construción da colección desenvolveuse mediante un proceso automatizado composto por catro etapas, representadas na Figura 2.




Figura 2: Diagrama de fluxo de construción da colección Drugs-SFT a partir de preguntas e respostas reais da páxina de respostas de Drugs.com.

En primeiro lugar, a extracción automatizada permitiu obter a gran escala as páxinas correspondentes ás preguntas dispoñibles na plataforma, mantendo a trazabilidade entre cada exemplo e a súa fonte orixinal. Para cada páxina extraéronse de forma automática tanto a pregunta formulada polo/a usuario/a como a resposta principal asociada, descartando elementos alleos ao contido médico, como publicidade, ligazóns de navegación

²<https://www.drugs.com/answers/>

³<https://www.who.int/news-room/fact-sheets>

Táboa 2: Comparativa das principais fontes de información sanitaria analizadas.

Plataforma	Fiabilidade	Estrutura	Volume	Seleccionada
Páxina de respostas de Drugs.com	Alta	Pregunta-resposta	Medio	Si
<i>WHO Fact Sheets</i>	Moi alta	Artigos	Medio	Si
MedlinePlus	Moi alta	Artigos	Baixo	Non
NHS	Moi alta	FAQ/artigos	Baixo	Non
Mayo Clinic Connect	Media	Foro	Medio	Non
Reddit AskDocs	Baixa	Foro	Moi alto	Non

ou recomendacións adicionais.

Nunha segunda fase, o proceso de limpeza garantiu que os exemplos incorporados ao corpus fosen completos, lexibles e consistentes. Elimináronse preguntas incompletas, corrixióronse problemas de codificación e verificouse que cada rexistro estivese composto exactamente por unha pregunta e unha resposta. Tamén se aplicaron mecanismos de deduplicación para evitar que exemplos repetidos influísen de maneira artificial no proceso de adaptación.

Finalmente, a conversión ao formato SFT permitiu transformar as interaccións extraídas nunha representación conversacional directamente empregable polos modelos de linguaxe. A pregunta orixinal transformouse nunha mensaxe de usuario/a, mentres que a resposta extraída pasou a ser a mensaxe do asistente. Ademais, incorporouse unha instrución inicial común para todos os exemplos e conservouse a ligazón de procedencia de cada rexistro, como se mostra de forma esquemática na Táboa 3. Como resultado obtívose a colección Drugs-SFT, composta por 3.609 pares pregunta-resposta, empregada posteriormente no proceso de adaptación dos modelos.

Táboa 3: Transformación abreviada dun rexistro de Drugs.com ao formato conversacional empregado no SFT.

Campo	Contido ou función
<i>Rexistro extraído (JSON)</i>	
question	<i>How long does it take for ivermectin to kill parasites?</i>
answer_text	<i>Ivermectin begins killing certain parasites within hours after administration...</i>
url	Ligazón orixinal da pregunta en Drugs.com.
<i>Exemplo de adestramento (JSONL)</i>	
messages[0]	system: instrución común para actuar como asistente de pregunta-resposta médica.
messages[1]	user: contido do campo question .
messages[2]	assistant: contido do campo answer_text .
source_url	Copia da URL de procedencia do rexistro extraído.

3.4. Construción da colección WHO-SFT

A construción da colección WHO-SFT respondeu a unha estratexia diferente da empregada en Drugs-SFT. Mentres que Drugs.com proporcionaba preguntas-respostas xa estruturadas, as *WHO Fact Sheets* ofrecen documentos divulgativos sen unha estrutura conversacional explícita. Isto obrigou a deseñar un procedemento

capaz de transformar automaticamente información médica estruturada nun corpus de adestramento para modelos de linguaxe. Esta segunda estratexia permite explorar se unha fonte institucional de alta fiabilidade, aínda que non estea formulada como preguntas e respostas, pode ser reutilizada para construír datos de adestramento.

O proceso comezou coa descarga das *WHO Fact Sheets* e coa extracción do seu contido textual, eliminando elementos propios da interface web. Posteriormente cada documento fragmentouse en unidades de tamaño adecuado para o seu procesamento polo modelo de linguaxe. A fragmentación realizouse a nivel de parágrafo, cun máximo de 4.500 caracteres por bloque e un solapamento dun parágrafo entre bloques consecutivos. Cando un parágrafo superaba o tamaño máximo, dividíase por oracións. Este procedemento permitiu manter a coherencia semántica de cada bloque, evitar cortes bruscos en información clínica relevante e reducir o risco de que o modelo omitise datos por recibir entradas demasiado extensas.

Sobre cada fragmento aplicouse un *prompt* especificamente deseñado para xerar automaticamente preguntas-respostas baseadas exclusivamente na información presente no documento. O deseño deste *prompt* buscaba maximizar a cobertura do coñecemento dispoñible, prohibindo explicitamente a introdución de información externa, a modificación de datos clínicos ou a xeración de respostas non sustentadas polo texto orixinal. Ademais, especificouse que a saída debía producirse nun formato JSON estruturado para facilitar o seu procesamento automático. A instrución completa empregada pode consultarse no Anexo B.

Para comprobar a consistencia técnica da colección, os pares xerados sometéronse a un proceso de validación automática. Nesta fase comprobouse a integridade da estrutura JSON, elimináronse rexistros incompletos, reparáronse pequenas inconsistencias sintácticas e descartáronse preguntas duplicadas. Este proceso permitiu conservar unicamente rexistros estruturalmente válidos e manter a súa trazabilidade respecto das fichas orixinais.

Finalmente, os pares válidos convertéronse ao mesmo formato conversacional empregado en Drugs-SFT. Como resultado, obtívose a colección WHO-SFT, formada por 4.057 pares pregunta-resposta xerados a partir de 237 *WHO Fact Sheets*. A Figura 3 ilustra o fluxo completo de creación da colección.




Figura 3: Diagrama de fluxo de creación da colección WHO-SFT mediante xeración de preguntas-respostas a partir das *WHO Fact Sheets*.

3.5. Integración das coleccións de adestramento

Unha vez construídas as coleccións Drugs-SFT e WHO-SFT, foi necesario unificar ambas nun formato común para facilitar o seu emprego durante o proceso de adaptación dos modelos. Aínda que a súa orixe é diferente, ambos corpus foron representados mediante pares pregunta-resposta convertidos a unha estrutura conversacional compatible coa plantilla de conversación dos modelos. Cada exemplo inclúe unha mensaxe de sistema común, a pregunta como mensaxe de usuario/a e a resposta como mensaxe de asistente.

Esta unificación permite empregar as coleccións por separado ou combinalas sen modificar o código de adestramento. Ademais, facilita a comparación experimental entre fontes: o efecto observado nos modelos pode atribuírse á natureza dos datos e non a diferenzas no formato de entrada. Para a colección combinada Drugs-SFT+WHO-SFT aplicouse unha concatenación dos dous JSONL e unha deduplicación por pregunta normalizada, evitando incorporar exemplos repetidos ao corpus final.

A Táboa 4 resume as coleccións de adestramento empregadas.

3.6. Modelos empregados

Co obxectivo de avaliar o impacto das coleccións de adestramento sobre modelos con diferentes capacidades, seleccionáronse dous modelos de linguaxe instruídos: Gemma 3 4B-IT e Qwen2.5 0.5B-Instruct [19, 20]. O modelo principal foi Gemma 3 4B-IT, empregado nunha versión cuantizada a 4 bits e distribuída por Unsloth. O seu tamaño medio permite analizar o efecto das coleccións sobre un modelo cunha capacidade de representación relevante, mantendo uns requisitos computacionais asumibles. Pola súa parte, Qwen2.5 0.5B-Instruct, tamén nunha versión instruída e cuantizada, empregouse como modelo de comparación de menor tamaño e cun rendemento de partida inferior, co obxectivo de comprobar se os efectos da adaptación se manteñen en modelos con diferentes capacidades.

A adaptación dos modelos realizouse empregando a técnica QLoRA (*Quantized Low-Rank Adaptation*), que permite especializar modelos de linguaxe mantendo conxelados os parámetros do modelo base e adestrando unicamente adaptadores LoRA de baixo rango. Esta aproximación reduce significativamente o custo computacional fronte ao *fine-tuning* completo e facilita a reproducibilidade dos experimentos, ao tempo que permite atribuír as diferenzas observadas á información incorporada durante o proceso de adaptación e non á modificación da arquitectura do modelo.

Antes da avaliación definitiva levouse a cabo unha fase exploratoria destinada á selección dunha configuración estable de hiperparámetros. As primeiras probas evidenciaron que configuracións máis agresivas producían un comportamento inestable durante o adestramento, polo que finalmente se optou por unha configuración máis conservadora, empregada de forma consistente en todos os experimentos comparativos. A Táboa 5 resume tanto a configuración exploratoria inicial como a configuración finalmente seleccionada.

Táboa 5: Configuracións QLoRA exploradas. A v2 é a empregada nos experimentos comparativos finais.

Hiperparámetro	v1	v2
Épocas	2	1
Taxa de aprendizaxe	$2 \cdot 10^{-4}$	$5 \cdot 10^{-5}$
Rango LoRA r	16	8
LoRA α	16	8
Dropout LoRA	0	0
Lonxitude máxima	2.048	1.024
Batch por GPU	2	2
Acumulación gradiente	4	4

Unha vez definida a configuración de adestramento, construíuse a matriz experimental empregada ao longo do traballo. Para ambos os modelos adestráronse adaptadores independentes utilizando as coleccións Drugs-SFT e WHO-SFT, mantendo idéntica configuración de hiperparámetros en todos os casos. Ademais, realizouse un experimento adicional con Gemma 3 4B-IT empregando a combinación de ambas as coleccións. Deste modo, as diferenzas observadas durante a avaliación poden atribuírse fundamentalmente ás características das coleccións de adestramento e non a cambios no procedemento de adaptación. A Táboa 6 presenta de forma resumida os experimentos realizados, todos eles avaliados sobre o MIRAGE completo.

Táboa 6: Matriz de experimentos realizados.

Modelo	Colección de adestramento
Gemma 3 4B-IT	Ningunha (modelo base)
	Drugs-SFT
	WHO-SFT
	Drugs-SFT + WHO-SFT
Qwen2.5 0.5B-Instruct	Ningunha (modelo base)
	Drugs-SFT
	WHO-SFT

Táboa 4: Resumo dos corpus SFT empregados nos experimentos de adestramento.

Corpus	Fonte	P-R	Tamaño	Tokens aprox.	Tipo
Drugs-SFT	Páxina de respostas de Drugs.com	3.609	13,75 MiB	2.574.042	P-R real
WHO-SFT	237 <i>WHO Fact Sheets</i>	4.057	2,39 MiB	287.540	P-R xerada
Drugs-SFT+WHO-SFT	Ambas fontes	7.664	16,14 MiB	2.861.582	Corpus combinado

3.7. Avaliación

A avaliación dos modelos base e dos seus respectivos adaptadores realizouse mediante un protocolo común, deseñado para medir os cambios introducidos polas diferentes coleccións de adestramento. Este protocolo baséase no *benchmark* MIRAGE, no emprego dunha selección restrinxida das respostas válidas e na exactitude como métrica principal. Ademais do rendemento global, analízanse os resultados obtidos en cada subconxunto, os cambios producidos pregunta a pregunta e a distribución das opcións seleccionadas polos modelos.

Para esta avaliación escolleuse MIRAGE⁴, un *benchmark* que integra diferentes conxuntos de preguntas médicas e permite estudar o comportamento dos modelos sobre tarefas heteroxéneas [21]. Aínda que foi proposto inicialmente no contexto de sistemas médicos baseados en recuperación e xeración aumentada, a súa composición permite empregalo tamén como conxunto de referencia para comparar o coñecemento médico dos modelos base e adaptados. A versión utilizada neste traballo está formada por 7.663 preguntas, distribuídas entre MedQA, MedMCQA, PubMedQA, BioASQ e MMLU médico, segundo se recolle na Táboa 7.

Táboa 7: Composición do *benchmark* MIRAGE empregado.

Conxunto	Preguntas
MedQA	1.273
MedMCQA	4.183
PubMedQA	500
BioASQ	618
MMLU médico	1.089
Total	7.663

Estes subconxuntos abranguen diferentes tipos de coñecemento e formatos de pregunta. MedQA, MedMCQA e MMLU médico conteñen principalmente preguntas de opción múltiple procedentes de exames ou probas de coñecemento [8, 9, 22]; PubMedQA presenta preguntas baseadas en literatura biomédica con respostas *yes*, *no* ou *maybe* [7]; e BioASQ inclúe preguntas médicas binarias [23]. Esta diversidade permite comprobar se os efectos da adaptación se manteñen de maneira uniforme ou se, pola contra, dependen das características de cada tarefa. Ao mesmo tempo, a heteroxeneidade das opcións de resposta fixo necesario establecer un procedemento que garantise unha comparación consistente entre todos os modelos.

Nunha primeira aproximación solicitouse aos modelos que xerasen unha resposta en texto libre, da que pos-

teriormente se extraía a opción seleccionada mediante expresións regulares. Non obstante, este procedemento resultou pouco robusto, xa que os modelos podían producir explicacións completas, respostas baleiras ou expresións como *Yes* e *No*, mentres que MIRAGE, na meirande parte das súas coleccións, representaba as opcións mediante identificadores como A, B ou C. Deste modo, a puntuación podía verse afectada pola capacidade do modelo para seguir o formato solicitado e non unicamente polo seu coñecemento médico.

Para evitar este problema, o protocolo definitivo emprega unha selección restrinxida das respostas. Para cada pregunta aplícase a plantilla conversacional correspondente ao modelo e límitase a xeración ás opcións válidas do exemplo. Se V_i representa o conxunto de respostas dispoñibles para a pregunta i , a opción seleccionada defínese como:

$$\hat{y}_i = \arg \max_{v \in V_i} p(v \mid x_i), \quad (1)$$

onde x_i representa a pregunta xunto coas súas opcións, e $p(v \mid x_i)$ é a probabilidade asignada polo modelo a cada resposta válida. A xeración realízase de maneira determinista e límitase á selección dun único identificador de resposta. Na implementación, esta restrición aplicouse directamente durante a xeración mediante os mecanismos proporcionados pola biblioteca *Transformers*. Este procedemento permite avaliar os modelos base e os adaptadores baixo as mesmas condicións e separar, na medida do posible, o coñecemento médico da capacidade para producir un formato textual concreto.

A métrica principal empregada é a exactitude, definida como a proporción de preguntas nas que a opción seleccionada polo modelo coincide coa resposta correcta:

$$\text{Acc} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[\hat{y}_i = y_i], \quad (2)$$

onde N é o número total de preguntas, y_i representa a resposta correcta e $\hat{y}_i$ a opción seleccionada polo modelo. A exactitude calculouse de maneira independente para cada subconxunto de MIRAGE e tamén de forma global. O valor global é promediado, polo que cada pregunta contribúe co mesmo peso, con independencia do subconxunto ao que pertence.

Ademais da exactitude, realizáronse dúas análises complementarias para caracterizar con maior detalle os cambios introducidos durante a adaptación. En primeiro lugar, comparouse a resposta obtida en cada pregunta polo modelo base e polo seu correspondente adaptador, distinguindo entre consultas melloradas, empeoradas, resoltas correctamente por ambos ou respondidas incorrectamente por ambos. En segundo lugar, analizouse a

⁴Repositorio oficial de MIRAGE

distribución das opcións seleccionadas polos modelos, co propósito de identificar posibles cambios nas preferencias de resposta derivados do proceso de *fine-tuning*. A significación das diferenzas entre cada modelo base e o seu correspondente adaptador avalíase mediante a proba de McNemar, tanto de forma global como por subconxunto. Para controlar o erro derivado das comparacións múltiples, os valores de p axustáronse mediante a corrección de Holm. Nas comparacións globais calculáronse tamén intervalos de confianza do 95 % para a diferenza pareada de exactitude, empregando como unidade de análise cada pregunta do benchmark.

3.8. Infraestrutura de execución

Os experimentos de adestramento e avaliación executáronse no clúster de computación do CiTIUS. A planificación das tarefas realizouse mediante Slurm, empregando un contorno Conda illado para manter unha configuración de software común entre as distintas execucións. Segundo a dispoñibilidade dos recursos, utilizáronse nodos equipados con GPUs NVIDIA L4 de 24 GB, NVIDIA Tesla V100S de 32 GB e NVIDIA A100 de 40 ou 80 GB de memoria. O emprego de modelos cuantizados a 4 bits e da técnica QLoRA permitiu executar os diferentes experimentos sobre estes recursos mantendo a mesma configuración de adaptación.

4. Resultados

Neste capítulo preséntanse os resultados obtidos ao avaliar os modelos base e os seus correspondentes adaptadores sobre o *benchmark* MIRAGE. A análise comeza coa validación preliminar da configuración de *fine-tuning*, que permitiu descartar unha primeira parametrización inestable e seleccionar a empregada nos experimentos definitivos. A continuación, examínase por separado o comportamento de Gemma 3 4B-IT e Qwen2.5 0.5B-Instruct, atendendo tanto á exactitude global como ás variacións observadas nos diferentes subconxuntos do benchmark.

A comparación complétase mediante unha análise pareada das predicións, que permite determinar cantas preguntas mellora e empeora cada adaptador respecto ao seu modelo de partida. Finalmente, estúdase a distribución das opcións seleccionadas para comprobar en que medida o proceso de adaptación modifica as preferencias de resposta dos modelos.

4.1. Validación da configuración experimental

Antes de realizar a avaliación completa, efectuouse unha proba preliminar sobre unha mostra determinista de 100 preguntas por subconxunto, co obxectivo de validar a configuración empregada durante o proceso de *fine-tuning*. A Táboa 8 resume os resultados obtidos coa primeira configuración (v1), aplicada a Gemma 3 4B-IT con Drugs-SFT.

Táboa 8: Validación inicial de Gemma 3 4B-IT e do seu primeiro adaptador Drugs-SFT (QLoRA v1), con selección restrinxida sobre 100 exemplos por conxunto.

Conxunto	Base	QLoRA v1	Δ	Corr. base	Corr. v1
MedQA	0,420	0,220	-0,200	42/100	22/100
MedMCQA	0,560	0,280	-0,280	56/100	28/100
PubMedQA	0,480	0,550	+0,070	48/100	55/100
BioASQ	0,680	0,650	-0,030	68/100	65/100
MMLU	0,560	0,240	-0,320	56/100	24/100
Global	0,540	0,388	-0,152	270/500	194/500

A primeira configuración, denominada v1, produciu unha degradación considerable do rendemento. Como se recolle na Táboa 8, o modelo base resolvía correctamente 270 das 500 preguntas da mostra, mentres que o primeiro adaptador Drugs-SFT reduciu esta cifra a 194 acertos. A exactitude global pasou así do 54,0 % ao 38,8 %, o que representa unha diminución de 15,2 puntos porcentuais.

A perda non se distribuíu de maneira uniforme entre os subconxuntos. MedQA, MedMCQA, BioASQ e MMLU presentaron reducións de exactitude, mentres que PubMedQA foi a única excepción, ao pasar de 48 a 55 respostas correctas. Con todo, a análise das predicións mostrou que esta mellora se producía dentro dun comportamento xeral pouco equilibrado: o adaptador seleccionaba a opción A no 90 % das preguntas de MedQA, no 94 % das de MedMCQA e MMLU, no 98 % das de PubMedQA e no 99 % das de BioASQ.

Esta forte concentración nunha única opción indicaba que a configuración inicial estaba modificando en exceso as preferencias de saída do modelo. Por este motivo, os resultados da v1 empregáronse unicamente como diagnóstico e non se consideraron representativos do rendemento definitivo dos adaptadores.

A partir desta observación definiuse unha segunda configuración, denominada v2, cunha taxa de aprendizaxe menor, unha única época de adestramento e un rango LoRA máis reducido, segundo os valores presentados na Táboa 5. Ao avaliar novamente a mesma mostra de 500 preguntas, o adaptador obtivo unha exactitude do 55,0 %, fronte ao 54,0 % do modelo base. Esta configuración máis conservadora foi, por tanto, a seleccionada para os experimentos completos que se presentan nos seguintes apartados.

4.2. Resultados obtidos con Gemma 3 4B-IT

A avaliación de Gemma 3 4B-IT mostra dous patróns diferenciados. Por unha banda, o adaptador adestrado con Drugs-SFT mantén un rendemento global moi próximo ao do modelo base. Por outra, WHO-SFT e, especialmente, a combinación directa das dúas coleccións producen perdas progresivamente maiores. En contraste con esta tendencia global, os tres adaptadores melloran a exactitude en PubMedQA. A Táboa 9 presenta os resultados completos.

Táboa 9: Avaliación completa de Gemma 3 4B-IT en MIRA-GE. Os deltas calcúlanse fronte ao modelo base. D: Drugs-SFT; W: WHO-SFT. D+W corresponde ao experimento exploratorio coa unión directa das dúas coleccións.

Conxunto	Base	D	Δ	W	Δ	D+W	Δ
MedQA	0,4745	0,4666	-0,0079	0,4430	-0,0314	0,4053	-0,0691
MedMCQA	0,4466	0,4449	-0,0017	0,4301	-0,0165	0,4114	-0,0351
PubMedQA	0,4880	0,5580	+0,0700	0,5600	+0,0720	0,5500	+0,0620
BioASQ	0,7071	0,6877	-0,0194	0,6683	-0,0388	0,6456	-0,0615
MMLU	0,5712	0,5510	-0,0202	0,5445	-0,0266	0,4683	-0,1028
Global	0,4926	0,4905	-0,0021	0,4762	-0,0164	0,4464	-0,0462

O modelo base resolve correctamente 3.775 das 7.663 preguntas de MIRAGE, o que corresponde a unha exactitude do 49,26 %. Tras a adaptación con Drugs-SFT, a cifra redúcese a 3.759 acertos e unha exactitude do 49,05 %. A diferenza entre ambos modelos é, por tanto, de só 16 respostas correctas, equivalentes a -0,21 puntos porcentuais.

O adaptador WHO-SFT presenta unha redución máis visible. Obtén 3.649 acertos e unha exactitude global do 47,62 %, o que supón 126 respostas correctas menos e unha redución de 1,64 puntos porcentuais respecto ao modelo base. A maior caída corresponde ao experimento exploratorio que combina Drugs-SFT e WHO-SFT mediante a unión directa das dúas coleccións. Neste caso, o modelo alcanza 3.421 acertos e unha exactitude do 44,64 %, o que supón 354 respostas correctas menos que o modelo de partida.

O comportamento por subconxuntos permite matizar estas diferenzas globais. Drugs-SFT mantén resultados próximos aos do modelo base en MedQA e MedMCQA, con variacións de -0,79 e -0,17 puntos porcentuais, respectivamente. As perdas son algo maiores en BioASQ e MMLU, onde a exactitude diminúe 1,94 e 2,02 puntos. PubMedQA segue a dirección contraria: o número de respostas correctas pasa de 244 a 279, o que representa unha mellora de 7,00 puntos porcentuais.

WHO-SFT tamén mellora o resultado de PubMedQA e alcanza 280 acertos, un máis que Drugs-SFT e 36 máis que o modelo base. Porén, esta mellora acompáñase de perdas nos demais subconxuntos: -3,14 puntos en MedQA, -1,65 en MedMCQA, -3,88 en BioASQ e -2,66 en MMLU.

A combinación das dúas coleccións conserva parte da mellora de PubMedQA, onde obtén 275 respostas correctas fronte ás 244 do modelo base. Non obstante, as reducións nos demais subconxuntos son máis pronunciadas: perde 88 acertos en MedQA, 147 en MedMCQA, 38 en BioASQ e 112 en MMLU. Deste modo, a mellora observada en PubMedQA non chega a compensar as perdas acumuladas nas restantes tarefas. Dado que a unión directa das coleccións produciu o peor resultado global dos experimentos con Gemma 3 4B-IT, este experimento non se repetiu con Qwen2.5 0.5B-Instruct.

4.3. Resultados obtidos con Qwen2.5 0.5B-Instruct

O comportamento de Qwen2.5 0.5B-Instruct difire do observado en Gemma 3 4B-IT. Neste modelo, tanto Drugs-SFT como WHO-SFT reducen a exactitude global, e a mellora de PubMedQA rexistrada en Gemma 3 4B-IT

non se reproduce. As variacións positivas concéntranse en BioASQ e, no caso de Drugs-SFT, tamén de maneira leve en MedQA. A Táboa 10 presenta os resultados completos.

Táboa 10: Avaliación completa de Qwen2.5 0.5B-Instruct en MIRAGE.

Conxunto	Base	Drugs-SFT	Δ	WHO-SFT	Δ
MedQA	0,3150	0,3197	+0,0047	0,2985	-0,0165
MedMCQA	0,2747	0,2525	-0,0222	0,2630	-0,0117
PubMedQA	0,5580	0,4980	-0,0600	0,5300	-0,0280
BioASQ	0,6505	0,6650	+0,0146	0,6650	+0,0146
MMLU	0,4206	0,4031	-0,0174	0,4013	-0,0193
Global	0,3509	0,3343	-0,0166	0,3384	-0,0125

Segundo a Táboa 10, o modelo base resolve correctamente 2.689 das 7.663 preguntas, cunha exactitude global do 35,09 %. O adaptador Drugs-SFT obtén 2.562 acertos e unha exactitude do 33,43 %, o que representa unha perda de 127 respostas correctas e 1,66 puntos porcentuais. WHO-SFT alcanza 2.593 acertos e un 33,84 % de exactitude, quedando 96 respostas e 1,25 puntos por debaixo do modelo base.

O comportamento tampouco é uniforme entre os subconxuntos. Drugs-SFT incrementa lixeiramente o rendemento en MedQA, onde pasa de 401 a 407 acertos, e en BioASQ, onde aumenta de 402 a 411. Estas melloras, de 0,47 e 1,46 puntos porcentuais, non compensan as perdas observadas nas restantes tarefas. A exactitude diminúe 2,22 puntos en MedMCQA, 1,74 en MMLU e 6,00 en PubMedQA, sendo esta última a maior redución.

WHO-SFT tamén mellora BioASQ ata alcanzar 411 respostas correctas, o mesmo resultado que Drugs-SFT. Nos demais subconxuntos, o adaptador perde 21 acertos en MedQA, 49 en MedMCQA, 14 en PubMedQA e 21 en MMLU. Aínda que a caída global é menor que coa colección Drugs-SFT, ningún dos dous adaptadores supera o rendemento de partida de Qwen2.5 0.5B-Instruct.

4.4. Comparación estatística

As Figuras 4 e 5 resumen o comportamento dos modelos base e adaptados. A nivel global, Drugs-SFT mantén Gemma 3 4B-IT practicamente no mesmo nivel que o modelo de partida, mentres que WHO-SFT e a combinación das dúas coleccións producen perdas progresivamente maiores. En Qwen2.5 0.5B-Instruct, os dous adaptadores reducen tamén a exactitude global. Porén, a Figura 5 mostra que estes resultados agregados ocultan comportamentos diferentes entre as tarefas: PubMedQA mellora nos tres adaptadores de Gemma 3 4B-IT, mentres que BioASQ presenta pequenas melloras en Qwen2.5 0.5B-Instruct.

Para avaliar se as diferenzas de exactitude entre cada modelo base e o seu adaptador eran estatisticamente significativas, aplicouse a proba de McNemar e calculáronse intervalos de confianza do 95 % para a diferenza pareada. Dado que se realizaron cinco comparacións globais, os valores de p axustáronse mediante a corrección de Holm. Os resultados recóllense na Táboa 11.




Figura 4: Exactitude global en MIRAGE para modelos base e adaptadores.




Figura 5: Variación de exactitude fronte ao modelo base correspondente.

Táboa 11: Comparacións pareadas globais entre os modelos base e os seus adaptadores. Os deltas e os intervalos exprésanse en puntos porcentuais. p_{Holm} corresponde ao valor p axustado nas cinco comparacións globais. G3: Gemma 3 4B-IT; Q0.5: Qwen2.5 0.5B-Instruct; D: Drugs-SFT; W: WHO-SFT.

Comp.	Δ (p.p.)	IC 95 %	p	p_{Holm}
G3+D	-0,21	[-0,99; +0,57]	0,623	0,623
G3+W	-1,64	[-2,54; -0,75]	0,00036	0,00108
G3+D+W	-4,62	[-5,72; -3,52]	$3,1 \cdot 10^{-16}$	$1,6 \cdot 10^{-15}$
Q0.5+D	-1,66	[-2,37; -0,94]	$6,2 \cdot 10^{-6}$	$2,5 \cdot 10^{-5}$
Q0.5+W	-1,25	[-1,99; -0,52]	0,00095	0,00190

Gemma 3 4B-IT+Drugs-SFT é a única comparación na que non se detecta unha diferenza global significativa. A súa exactitude diminúe 0,21 puntos porcentuais, pero o intervalo de confianza inclúe o cero $([-0,99; +0,57])$ e a proba de McNemar produce $p_{\text{Holm}} = 0,623$. Polo tanto, os resultados non permiten afirmar que este adaptador presente un rendemento global diferente ao do modelo base.

Nas restantes comparacións, os intervalos sitúanse completamente por debaixo de cero e os valores axustados son inferiores a 0,05. As perdas son de 1,64 puntos para Gemma+WHO-SFT ($p_{\text{Holm}} = 0,00108$), 4,62 para o adaptador combinado ($p_{\text{Holm}} = 1,6 \cdot 10^{-15}$), 1,66 para Qwen+Drugs-SFT ($p_{\text{Holm}} = 2,5 \cdot 10^{-5}$) e 1,25 para

Qwen+WHO-SFT ($p_{\text{Holm}} = 0,00190$). En consecuencia, todos os adaptadores agás Gemma+Drugs-SFT presentan unha diminución estatisticamente significativa da exactitude global respecto ao seu modelo de partida.

Para identificar en que tarefas se concentran estas variacións, repetiuse a proba de McNemar de maneira independente nos cinco subconxuntos de MIRAGE. Dentro de cada adaptador, os cinco valores de p obtidos axustáronse mediante a corrección de Holm. A Táboa 12 presenta conxuntamente a magnitude da diferenza e o seu valor de p axustado, evitando separar a significación estatística da dirección do cambio.

A análise por subconxunto identifica un patrón especialmente claro en Gemma 3 4B-IT. PubMedQA mellora significativamente cos tres adaptadores: +7,00 puntos con Drugs-SFT ($p_{\text{Holm}} = 7,9 \cdot 10^{-5}$), +7,20 con WHO-SFT ($p_{\text{Holm}} = 2,8 \cdot 10^{-4}$) e +6,20 coa combinación das coleccións ($p_{\text{Holm}} = 6,4 \cdot 10^{-4}$).

No caso de Gemma+Drugs-SFT, PubMedQA é o único subconxunto cunha variación significativa. As perdas observadas nas restantes tarefas non superan o limiar de significación tras a corrección, polo que a mellora de PubMedQA queda compensada no resultado global sen producir unha diferenza estatisticamente detectable respecto ao modelo base.

WHO-SFT presenta un comportamento diferente. A mellora de PubMedQA acompáñase de perdas signifi-

Táboa 12: Diferenza de exactitude respecto ao modelo base e valor de p axustado mediante a corrección de Holm en cada subconxunto. Cada cela presenta Δ en puntos porcentuais e, entre parénteses, p_{Holm} . A letra grosa indica $p_{\text{Holm}} < 0,05$.

Comparación	MedQA	MedMCQA	PubMedQA	BioASQ	MMLU
G3+D	-0,79 (0,931)	-0,17 (0,931)	+7,00 ($7,9 \cdot 10^{-5}$)	-1,94 (0,0676)	-2,02 (0,183)
G3+W	-3,14 (0,0171)	-1,65 (0,0271)	+7,20 ($2,8 \cdot 10^{-4}$)	-3,88 (0,00155)	-2,66 (0,0271)
G3+D+W	-6,91 ($4,4 \cdot 10^{-6}$)	-3,51 ($3,3 \cdot 10^{-5}$)	+6,20 ($6,4 \cdot 10^{-4}$)	-6,15 ($1,0 \cdot 10^{-6}$)	-10,28 ($1,6 \cdot 10^{-11}$)
Q0.5+D	+0,47 (0,666)	-2,22 ($3,9 \cdot 10^{-6}$)	-6,00 (0,0896)	+1,46 (0,422)	-1,74 (0,184)
Q0.5+W	-1,65 (0,279)	-1,17 (0,0729)	-2,80 (0,279)	+1,46 (0,279)	-1,93 (0,211)

cativas en MedQA, MedMCQA, BioASQ e MMLU. A combinación de Drugs-SFT e WHO-SFT reproduce este patrón de maneira máis acusada: mellora significativamente PubMedQA, pero empeora tamén de forma significativa os outros catro subconxuntos, especialmente MMLU, cunha diminución de 10,28 puntos porcentuais.

En Qwen2.5 0.5B-Instruct non se observa ningunha mellora estatisticamente significativa. Con Drugs-SFT, a única diferenza que permanece significativa tras a corrección é a perda de 2,22 puntos en MedMCQA ($p_{\text{Holm}} = 3,9 \cdot 10^{-6}$). Con WHO-SFT, ningunha das variacións por subconxunto acada significación estatística, aínda que o seu balance conxunto produce unha perda global significativa.

En síntese, a análise estatística confirma dúas conclusións complementarias. A primeira é que todos os adaptadores, agás Gemma+Drugs-SFT, reducen significativamente a exactitude global. A segunda é que PubMedQA constitúe unha excepción consistente nos experimentos con Gemma: mellora significativamente cos tres adaptadores, aínda que esta ganancia non chega a compensar as perdas producidas noutras tarefas.

4.5. Análise por consulta

A exactitude global resume o balance final de acertos, mais non permite determinar cantas preguntas cambian a súa condición de acerto nin en que dirección o fan. Por este motivo, comparouse pregunta a pregunta cada modelo base co seu correspondente adaptador. Unha pregunta considérase mellorada cando o modelo base falla e o adaptador acerta, e empeorada cando o modelo base acerta e o adaptador falla. A Táboa 13 recolle estes catro posibles resultados e o seu balance global para as 7.663 preguntas do benchmark.

Táboa 13: Cambios pregunta a pregunta entre modelo base e adaptador. G3: Gemma 3 4B-IT; Q0.5: Qwen2.5 0.5B-Instruct; D: Drugs-SFT; W: WHO-SFT.

Comp.	Melloras	Perdas	Acerto común	Erro común	Balance
G3+D	458	474	3.301	3.430	-16
G3+W	552	678	3.097	3.336	-126
G3+D+W	762	1.116	2.659	3.126	-354
Q0.5+D	327	454	2.235	4.647	-127
Q0.5+W	366	462	2.227	4.608	-96

No caso de Gemma 3 4B-IT+Drugs-SFT, obsérvanse 458 melloras e 474 empeoramentos, cun balance de -16 preguntas. Polo tanto, o adaptador modifica a condición de acerto en 932 preguntas, mais o número de novas respostas correctas e o de acertos perdidos resultan practicamente equivalentes. Con Gemma 3 4B-IT+WHO-SFT rexístranse 552 melloras fronte a 678 empeoramentos, o

que produce un balance de -126. O adaptador combinado presenta o cambio máis acusado: 762 preguntas pasan de incorrectas a correctas e 1.116 pasan de correctas a incorrectas, sumando 1.878 cambios na condición de acerto e un balance de -354.

No modelo Qwen2.5 0.5B-Instruct, Drugs-SFT presenta 327 melloras e 454 empeoramentos, mentres que WHO-SFT presenta 366 e 462, respectivamente. A Figura 6 permite comparar visualmente estes balances e mostra que os empeoramentos superan as melloras nas cinco comparacións analizadas.

A distribución dos cambios tampouco é uniforme entre subconxuntos. Para Gemma 3 4B-IT+Drugs-SFT, PubMedQA concentra 50 melloras e 15 empeoramentos, mentres que MMLU presenta 52 melloras e 74 empeoramentos. Para Gemma 3 4B-IT+WHO-SFT, PubMedQA reúne 57 melloras e 21 empeoramentos, fronte ás 345 melloras e 414 empeoramentos de MedMCQA. No caso de Qwen2.5 0.5B-Instruct+Drugs-SFT, o maior balance negativo corresponde tamén a MedMCQA, con 129 melloras e 222 empeoramentos. Pola súa parte, as dúas adaptacións de Qwen2.5 0.5B-Instruct incrementan en nove o número neto de acertos de BioASQ.

A Táboa 14 ofrece exemplos ilustrativos de preguntas que mudan en ambas direccións. As preguntas resúmen-se para facilitar a lectura; a comparación conserva en todos os casos a pregunta e as opcións completas do benchmark.

Táboa 14: Exemplos ilustrativos de cambios pregunta a pregunta. A frecha representa a opción do modelo base e a do adaptador; a resposta correcta indícase entre parénteses.

Comp.	Cambio	Pregunta resumida	Predición
G3+D	Mellora	BioASQ: eficacia de riloncept B na pericardite	B → A (A)
G3+D	Empeora	BioASQ: <i>Mycobacterium abscessus</i> é un patóxeno humano?	A → B (A)
G3+W	Mellora	MedMCQA: encima que rexe- nera a vitamina K na súa forma de coenzima	C → D (D)
G3+W	Empeora	MedMCQA: estrutura alterada por <i>Vibrio cholerae</i>	C → A (C)
Q0.5+D	Mellora	BioASQ: a hidrolóxía médica é equivalente á terapia de spa?	A → B (B)
Q0.5+D	Empeora	MedMCQA: definición de hipo- natremia	A → D (A)

4.6. Distribución de respostas

Ademais da exactitude, analizouse a distribución das opcións seleccionadas polos modelos para caracterizar os cambios de comportamento introducidos pola adaptación. A análise centrouse na opción A, xa que as variacións




Figura 6: Preguntas melloradas e empeoradas polos adaptadores.

observadas nesta alternativa permitían caracterizar un posible cambio sistemático nas preferencias de resposta. A Figura 7 compara a frecuencia desta opción nas respostas correctas e nas predicións dos modelos.

No caso de Gemma 3 4B-IT, a frecuencia de A xa é superior á súa presenza nas respostas correctas antes do fine-tuning e aumenta na maioría dos adaptadores. En PubMedQA, por exemplo, A constitúe a resposta correcta no 55,2 % das preguntas, fronte ao 76,0 % das predicións do modelo base, ao 88,8 % con Drugs-SFT e ao 94,2 % con WHO-SFT. A combinación das dúas coleccións alcanza o 97,8 %.

Nas tarefas de opción múltiple, o mesmo adaptador combinado selecciona A no 65,2 % das preguntas de MedQA, no 62,9 % de MedMCQA e no 54,1 % de MMLU médico. Estas proporcións superan amplamente a porcentaxe de preguntas nas que A é a resposta correcta: 27,7 % en MedQA, 32,2 % en MedMCQA e 21,6 % en MMLU médico. A figura permite así observar que a variación da exactitude vén acompañada de cambios substanciais na preferencia polas opcións de saída.

O comportamento de Qwen2.5 0.5B-Instruct nas preguntas de catro alternativas é distinto. A frecuencia de A diminúe despois da adaptación, do 12,2 % ao 5,9 % con Drugs-SFT e ao 2,9 % con WHO-SFT en MedQA, e do 13,1 % a aproximadamente o 4 % en MedMCQA. Pola contra, nas tarefas binarias ou ternarias A continúa sendo unha resposta moi frecuente: en PubMedQA pasa do 85,6 % no modelo base ao 49,4 % con Drugs-SFT e ao 56,6 % con WHO-SFT, e en BioASQ mantense por riba do 91 % nos tres modelos.

En consecuencia, a adaptación non só modifica o número de acertos, senón tamén a distribución das opcións seleccionadas. A dirección e a magnitude destes cambios dependen tanto do modelo base como do formato de cada subconxunto de avaliación.




Figura 7: Frecuencia da primeira opción nas etiquetas correctas e nas predicións. En MedQA, MedMCQA e MMLU, A representa a primeira alternativa; en PubMedQA e BioASQ representa *yes*.

5. Discusión

Os resultados obtidos mostran que a adaptación mediante SFT non produce un efecto uniforme sobre o rendemento dos modelos. As coleccións construídas modifican de maneira apreciable as predicións dos modelos, mais estas variacións non se traducen necesariamente nunha mellora global en MIRAGE. O impacto depende da colección empregada, do modelo de partida e das

características de cada subconxunto de avaliación.

Drugs-SFT e WHO-SFT parten de fontes de natureza diferente e presentan características tamén distintas. Drugs-SFT conserva consultas reais e respostas elaboradas ou revisadas por profesionais sanitarios, mentres que WHO-SFT transforma documentos institucionais nunha colección conversacional mediante xeración automática. A primeira achega exemplos próximos a situacións reais, aínda que heteroxéneos, e a segunda permite aproveitar información médica fiable e manter a trazabilidade cara ás fontes orixinais.

Os resultados non permiten identificar unha colección superior de maneira uniforme. En Gemma 3 4B-IT, Drugs-SFT mantén unha exactitude global moi próxima á do modelo base, mentres que WHO-SFT produce unha perda maior. En Qwen2.5 0.5B-Instruct, pola contra, os dous corpus reducen o rendemento global e WHO-SFT presenta unha caída menor que Drugs-SFT. Polo tanto, a vantaxe relativa dunha colección cambia en función do modelo sobre o que se aplica.

A análise pareada reforza esta lectura. Gemma 3 4B-IT+Drugs-SFT é a única comparación na que non se detecta unha diferenza estatisticamente significativa respecto ao modelo base, mentres que as restantes adaptacións presentan perdas globais significativas. Isto non implica que Drugs-SFT sexa unha colección mellor en termos absolutos, senón que foi a única que conservou globalmente o rendemento dun dos modelos avaliados.

A comparación entre Drugs-SFT e WHO-SFT debe interpretarse con cautela. As coleccións non difiren unicamente na procedencia e no proceso de construción dos exemplos, senón tamén no volume de *tokens*, na lonxitude das respostas, no estilo lingüístico, na distribución temática e no procedemento de validación. Aínda que WHO-SFT reúne máis exemplos, Drugs-SFT contén un volume de texto considerablemente maior. En consecuencia, o número de pares de preguntas e respostas non representa por si só a cantidade de información á que se expón o modelo.

O experimento coa combinación das dúas coleccións confirma a importancia destas diferenzas. A súa unión directa non produce un efecto complementario en Gemma 3 4B-IT, senón que reduce a exactitude global ata o 44,64 %. A concatenación equilibra aproximadamente o número de exemplos de cada procedencia, pero non o seu peso en tokens, xa que Drugs-SFT representa arredor do 90 % do volume textual do corpus combinado. A degradación observada mostra que engadir máis exemplos non garante unha adaptación mellor cando non se controla a contribución relativa, o formato e a distribución dos datos.

O efecto das coleccións tampouco pode separarse das características do modelo de partida. Gemma 3 4B-IT e Qwen2.5 0.5B-Instruct difiren no tamaño, na arquitectura, no predestramento e no axuste instrucional, ademais de partir de niveis de rendemento e distribucións de resposta distintos. A adaptación parte, polo tanto, de modelos con representacións internas e preferencias de resposta diferentes.

Esta dependencia apréciase con claridade ao comparar Drugs-SFT nos dous modelos. En Gemma 3 4B-IT, o adaptador conserva practicamente a exactitude global

e mellora PubMedQA en sete puntos porcentuais. En Qwen2.5 0.5B-Instruct, a mesma colección reduce a exactitude global en 1,66 puntos e empeora PubMedQA en seis. WHO-SFT tamén produce efectos diferentes: reduce o rendemento dos dous modelos, pero a magnitude da perda e os subconxuntos afectados non coinciden.

Qwen2.5 0.5B-Instruct foi seleccionado precisamente como referencia de menor tamaño e rendemento inicial. Podería esperarse que un modelo cunha puntuación de partida máis baixa ofrecese unha maior marxe de mellora, pero os experimentos non mostran esta tendencia. Os adaptadores corrixen determinadas preguntas e producen unha pequena mellora agregada en BioASQ, pero tamén alteran predicións previamente correctas e modifican de maneira notable a distribución das opcións seleccionadas.

A dependencia do modelo base observada nos experimentos reforza a conveniencia, sinalada na literatura, de avaliar os modelos médicos sobre tarefas e arquitecturas diversas [1, 3]. Unha mellora observada nun único modelo non debe interpretarse como unha propiedade xeral do corpus, xa que a transferencia depende da interacción entre os datos incorporados e o coñecemento xa representado polo modelo base.

PubMedQA presenta o comportamento máis diferenciado entre os subconxuntos avaliados. En Gemma 3 4B-IT, Drugs-SFT incrementa a exactitude do 48,80 % ao 55,80 %, mentres que WHO-SFT alcanza o 56,00 %. A colección combinada tamén mantén unha mellora neste subconxunto, aínda que o seu rendemento global diminúe de maneira considerable. En Qwen2.5 0.5B-Instruct, pola contra, as dúas adaptacións reducen a exactitude de PubMedQA.

Un dos factores que poden contribuír a este resultado son as características específicas da tarefa. PubMedQA está formado por preguntas baseadas en literatura biomédica e emprega as respostas *yes*, *no* e *maybe* [7]. Drugs-SFT e WHO-SFT tamén conteñen coñecemento médico formulado en estruturas de pregunta e resposta, pero non reproducen directamente este formato pechado, xa que as súas respostas son abertas e, en moitos casos, extensas. Polo tanto, a mellora non pode atribuírse simplemente a unha correspondencia directa entre os formatos de adestramento e avaliación.

A distribución das opcións ofrece información adicional. En PubMedQA, a opción A —correspondente a *yes*— é a resposta correcta no 55,2 % das preguntas. Gemma 3 4B-IT selecciónaa no 76,0 % das preguntas antes da adaptación, frecuencia que aumenta ata o 88,8 % con Drugs-SFT, o 94,2 % con WHO-SFT e o 97,8 % coa colección combinada. Este incremento coincide coa mellora da exactitude, pero supera amplamente a proporción real de respostas afirmativas, polo que non pode interpretarse como unha mellor calibración.

O comportamento de Qwen2.5 0.5B-Instruct mostra que a frecuencia agregada dunha opción non explica por si soa o rendemento. Os adaptadores aproximan a frecuencia da opción A á súa proporción real, pero a exactitude diminúe. Isto indica que non abonda con reproducir a distribución global das etiquetas: o modelo debe seleccionar a opción adecuada en cada pregunta concreta.

En consecuencia, a mellora de Gemma 3 4B-IT en

PubMedQA parece responder a unha combinación de factores. A adaptación modifica as preferencias de saída, pero tamén altera as predicións de preguntas concretas. Os experimentos non permiten determinar que parte da mellora procede do coñecemento incorporado e que parte está relacionada co cambio na distribución das respostas. O resultado debe interpretarse como unha interacción entre o modelo base, o contido das coleccións, o formato da tarefa e a distribución das etiquetas.

5.1. Implicacións para a construción de coleccións de adestramento

Os experimentos permiten extraer varias implicacións para a creación de coleccións médicas destinadas ao SFT. A primeira é que a calidade dunha colección non pode definirse mediante unha única propiedade. Ademais da fiabilidade da fonte, resultan relevantes a cobertura temática, a diversidade das preguntas, a lonxitude e o estilo das respostas, a distribución dos formatos e o volume real de tokens.

Drugs-SFT e WHO-SFT presentan vantaxes diferentes. A primeira conserva a formulación espontánea de consultas reais, mentres que a segunda permite transformar documentación institucional en novos exemplos de adestramento, unha estratexia potencialmente escalable e coherente con outros traballos de xeración automática de instrucións biomédicas [5]. Con todo, os resultados non permiten concluír que as coleccións baseadas en preguntas e respostas reais sexan sempre máis eficaces ca as construídas mediante xeración automática nin que unha fonte institucional produza necesariamente un corpus máis eficaz.

A segunda implicación é que a combinación de coleccións require algo máis que concatenar os rexistros. Para aproveitar fontes complementarias cómpre controlar a súa contribución en exemplos e tokens, así como equilibrar temas, tipos de pregunta e lonxitudes de resposta. A degradación obtida con Drugs-SFT+WHO-SFT mostra que o aumento do volume pode intensificar determinados patróns sen producir unha mellora proporcional do rendemento médico global medido en MIRAGE.

A terceira implicación afecta á validación. No caso de WHO-SFT, a comprobación da estrutura JSON, a eliminación de rexistros incompletos, a deduplicación e a conservación da procedencia permitiron construír unha colección tecnicamente consistente e trazable. Unha metodoloxía máis completa debería complementar estas comprobacións automáticas coa avaliación semántica e coa revisión de persoal experto dunha mostra representativa.

Finalmente, os resultados mostran a importancia de considerar conxuntamente o dominio e o formato da tarefa. Un corpus pode conter información médica fiable e, aínda así, non mellorar un benchmark formado principalmente por preguntas de elección múltiple. Incorporar formatos variados, respostas breves e preguntas pechadas podería favorecer un comportamento máis estable entre tarefas, sen renunciar ás consultas abertas.

5.2. Limitacións da adaptación mediante SFT

A análise pregunta a pregunta mostra que os adaptadores non producen unicamente pequenas variacións na puntuación global. Todos corrixen centos de preguntas que os modelos base respondían incorrectamente, pero tamén fan que fallen outras que antes resolvían correctamente. O SFT produce así unha transferencia parcial: introduce cambios favorables para determinadas consultas, mais non preserva necesariamente todas as capacidades previas.

A configuración inicial v1 mostra, ademais, que o resultado depende da configuración empregada. A configuración v1, con dúas épocas, unha taxa de aprendizaxe de $2 \cdot 10^{-4}$ e un rango LoRA maior, produciu nesta proba unha perda de 15,2 puntos. Por este motivo, nos experimentos principais empregouse unha configuración máis conservadora, que produciu un comportamento máis estable nos experimentos posteriores.

En conxunto, estes resultados mostran que a adaptación non depende unicamente da características da colección, senón tamén da configuración empregada para incorporala ao modelo. A especialización require, polo tanto, equilibrar a modificación do comportamento coa conservación do rendemento previo.

6. Limitacións e consideracións éticas

Os resultados deben interpretarse tendo en conta limitacións relacionadas coa construción das coleccións, o deseño experimental e o protocolo de avaliación, que limitan a xeneralización dos resultados a outros modelos, corpus ou escenarios de uso.

Drugs-SFT contén preguntas reais e respostas elaboradas ou revisadas por profesionais sanitarios, pero os exemplos non foron revisados individualmente neste traballo e poden presentar calidade desigual, información desactualizada ou formulacións ambiguas. WHO-SFT foi xerada automaticamente a partir de documentación institucional fiable; as comprobacións realizadas permitiron verificar a integridade estrutural, a deduplicación e a trazabilidade dos rexistros, pero non substitúen unha revisión clínica e semántica.

Tampouco é posible illar o efecto individual das características de cada colección, xa que difiren simultaneamente na procedencia, no volume de tokens, na lonxitude das respostas, no estilo e na distribución temática. Do mesmo xeito, a colección combinada construíuse mediante concatenación directa, sen un balanceo específico por temas, formatos ou volume textual.

O estudo abrangue só Gemma 3 4B-IT e Qwen2.5 0.5B-Instruct, polo que as tendencias observadas non poden extrapolarse automaticamente a outras familias ou tamaños. Ademais, a configuración seleccionouse mediante unha fase exploratoria e os adestramentos non se repetiron con diferentes sementes, polo que non se cuantificou toda a variabilidade do proceso de optimización.

MIRAGE permite comparar os modelos en diferentes tarefas médicas, pero está composto principalmente por

preguntas pechadas. A exactitude mide a selección da opción correcta, mais non avalía a calidade das explicacións, a precisión factual en respostas abertas, a calibración ou a capacidade para recoñecer a incerteza. A selección restrinxida mellora a consistencia da comparación, pero non reproduce unha interacción médica real nin permite avaliar por si soa a fiabilidade clínica dos modelos.

Desde o punto de vista ético, os modelos adaptados son prototipos de investigación e non ferramentas destinadas ao diagnóstico ou á toma de decisións clínicas. As fontes poden conter nesgos demográficos, lingüísticos ou sociais, que poderían reproducirse ou amplificarse durante a adaptación. Calquera aplicación práctica requiriría supervisión profesional, mecanismos de abstención, mecanismos de actualización do coñecemento, protección da información sensible e respecto polas condicións de uso das fontes orixinais.

7. Conclusións e traballo futuro

Este traballo abordou a construción de coleccións especializadas de preguntas e respostas médicas e o estudo da súa utilidade para adaptar modelos de linguaxe mediante SFT. Para iso, deseñouse unha metodoloxía reproducible que abrangue a selección das fontes de información, a extracción e transformación do contido, a validación dos rexistros, a adaptación eficiente dos modelos mediante QLoRA e a súa avaliación sobre o benchmark MIRAGE.

Como resultado deste proceso construíronse dúas coleccións con características complementarias. Drugs-SFT reúne preguntas e respostas reais procedentes dunha plataforma especializada, mentres que WHO-SFT transforma automaticamente documentación institucional da Organización Mundial da Saúde en novos pares de adestramento. Ademais do seu emprego nos experimentos, estas coleccións constitúen un dos principais resultados do traballo, xa que conservan unha estrutura común, a procedencia dos exemplos e os elementos necesarios para a súa revisión e ampliación posterior.

A avaliación realizada mostra que a adaptación ao dominio médico non garante por si soa unha mellora global do rendemento. En Gemma 3 4B-IT, Drugs-SFT mantivo unha exactitude próxima á do modelo base, mentres que WHO-SFT e a combinación directa de ambas as coleccións produciron reducións máis pronunciadas. En Qwen2.5 0.5B-Instruct, os dous adaptadores diminuíron tamén a exactitude global. Ao mesmo tempo, todos os experimentos modificaron centos de predicións individuais e produciron melloras en tarefas concretas, o que evidencia que o efecto do SFT non é uniforme, senón que depende da interacción entre a colección de adestramento, o modelo de partida e o subconxunto de avaliación.

A mellora observada en PubMedQA con Gemma 3 4B-IT constitúe o resultado positivo máis destacado, aínda que debe interpretarse con prudencia. A análise da distribución das opcións mostrou que a adaptación tamén incrementou a preferencia do modelo polas respostas afirmativas, polo que os experimentos non permiten atribuír toda a mellora exclusivamente á incorporación de novo coñecemento médico. Este resultado pon de manifesto a importancia de complementar as métricas agregadas con

análises por pregunta e por distribución de respostas.

A principal conclusión deste estudo é que a construción das coleccións de adestramento debe considerarse unha parte central do proceso de especialización dos modelos e non un paso previo meramente instrumental. A fiabilidade da fonte é necesaria, pero non suficiente: tamén inflúen o volume efectivo de texto, a lonxitude e o estilo das respostas, a diversidade temática, o formato dos exemplos e a súa correspondencia coas tarefas de avaliación. Do mesmo xeito, a concatenación de coleccións non garante un efecto complementario se non se controla a contribución relativa e a distribución dos datos.

Como continuación deste traballo, resultaría de especial interese incorporar unha revisión clínica dunha mostra representativa das coleccións, especialmente dos exemplos xerados automaticamente en WHO-SFT, e desenvolver mecanismos de filtrado semántico máis esixentes. Tamén sería conveniente construír combinacións equilibradas por volume de tokens, temática e formato de resposta, incluíndo exemplos de elección múltiple e respostas breves sen renunciar ás consultas abertas.

Desde o punto de vista experimental, futuras investigacións deberían repetir os adestramentos con distintas sementes, avaliar os *checkpoints* intermedios e ampliar a comparación a outras familias e tamaños de modelos. Así mesmo, a avaliación en MIRAGE podería complementarse con tarefas de resposta aberta, métricas de calibración e revisión experta, co fin de analizar non só a selección da opción correcta, senón tamén a precisión factual, a calidade explicativa e a seguridade das respostas xeradas.

En conxunto, os recursos e o protocolo desenvolvidos proporcionan unha base reproducible para continuar estudando como as decisións adoptadas durante a construción dos datos condicionan a especialización dos modelos de linguaxe no dominio médico. Os resultados obtidos non demostran que unha única estratexia de construción sexa universalmente superior, pero si evidencian que o deseño, a validación e o aliñamento das coleccións coa tarefa final son factores determinantes para avanzar cara a sistemas de pregunta-resposta médica máis robustos e fiables.

Referencias

- [1] Michael Moor, Oishi Banerjee, Zahra Shakeri Hossein Abad, Harlan M. Krumholz, Jure Leskovec, Eric J. Topol, and Pranav Rajpurkar. Foundation models for generalist medical artificial intelligence. *Nature*, 616:259–265, 2023. doi: 10.1038/s41586-023-05881-4.
- [2] Karan Singhal, Tao Tu, Juraj Gottweis, Rory Sayres, Ellery Wulczyn, Le Hou, Kevin Clark, Stephen Pfohl, Heather Cole-Lewis, Darlene Neal, et al. Toward expert-level medical question answering with large language models. *Nature Medicine*, 31: 943–950, 2025. doi: 10.1038/s41591-024-03423-7.
- [3] Shubo Tian, Qiao Jin, Lana Yeganova, Po-Ting Lai, Qingqing Zhu, Xiuying Chen, Yifan Yang, Qingyu Chen, Won Kim, Donald C. Comeau, Rezarta Islamaj, Aadit Kapoor, Xin Gao, and Zhiyong Lu. Opportunities and challenges for ChatGPT and large language models in biomedicine and health. *Briefings in Bioinformatics*, 25(1):bbad493, 2024. doi: 10.1093/bib/bbad493.
- [4] Satya S. Sahoo et al. Large language models for biomedicine: Foundations, opportunities, challenges, and best practices. *Journal of the American Medical Informatics Association*, 31(9):2114–2124, 2024. doi: 10.1093/jamia/ocae074.
- [5] Hieu Tran, Zhichao Yang, Zonghai Yao, and Hong Yu. BioInstruct: Instruction tuning of large language models for biomedical natural language processing. *Journal of the American Medical Informatics Association*, 31(9):1821–1832, 2024. doi: 10.1093/jamia/ocae122.
- [6] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020.
- [7] Qiao Jin, Bhuwan Dhingra, Zhengping Liu, William W. Cohen, and Xinghua Lu. PubMedQA: A dataset for biomedical research question answering. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing*, pages 2567–2577. Association for Computational Linguistics, 2019. doi: 10.18653/v1/D19-1259.
- [8] Di Jin, Eileen Pan, Nassim Oufattole, Wei-Hung Weng, Hanyi Fang, and Peter Szolovits. What disease does this patient have? A large-scale open domain question answering dataset from medical exams. *Applied Sciences*, 11(14):6421, 2021. doi: 10.3390/app11146421.
- [9] Ankit Pal, Logesh Kumar Umapathi, and Malai-kannan Sankarasubbu. MedMCQA: A large-scale multi-subject multi-choice dataset for medical domain question answering. In *Proceedings of the Conference on Health, Inference, and Learning*, volume 174 of *Proceedings of Machine Learning Research*, pages 248–260, 2022.
- [10] Karan Singhal, Shekoofeh Azizi, Tao Tu, S. Sara Mahdavi, Jason Wei, Hyung Won Chung, Nathan Scales, Ajay Tanwani, Heather Cole-Lewis, Stephen Pfohl, et al. Large language models encode clinical knowledge. *Nature*, 620:172–180, 2023. doi: 10.1038/s41586-023-06291-2.
- [11] Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. OpenAI technical report, 2019.
- [12] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, volume 33, pages 1877–1901, 2020.
- [13] OpenAI. GPT-4 technical report. *arXiv preprint arXiv:2303.08774*, 2023. doi: 10.48550/arXiv.2303.08774.
- [14] Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. BioBERT: A pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240, 2020. doi: 10.1093/bioinformatics/btz682.
- [15] Yu Gu, Robert Tinn, Hao Cheng, Michael Lucas, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 1(1):1–23, 2021. doi: 10.1145/3458754.
- [16] Yanis Labrak, Adrien Bazoge, Emmanuel Morin, Pierre-Antoine Gourraud, Mickael Rouvier, and Richard Dufour. BioMistral: A collection of open-source pretrained large language models for medical domains. *arXiv preprint arXiv:2402.10373*, 2024. doi: 10.48550/arXiv.2402.10373.
- [17] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*, 2022.
- [18] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems*, volume 36, pages 10088–10115, 2023.

- [19] Gemma Team et al. Gemma 3 technical report. *arXiv preprint arXiv:2503.19786*, 2025. doi: 10.48550/arXiv.2503.19786.
- [20] Qwen Team. Qwen2.5 technical report. *arXiv preprint arXiv:2412.15115*, 2024. doi: 10.48550/arXiv.2412.15115.
- [21] Guangzhi Xiong, Qiao Jin, Zhiyong Lu, and Aidong Zhang. Benchmarking retrieval-augmented generation for medicine. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 6233–6251. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.findings-acl.372.
- [22] Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt. Measuring massive multitask language understanding. In *International Conference on Learning Representations*, 2021.
- [23] George Tsatsaronis, Georgios Balikas, Prodromos Malakasiotis, Ioannis Partalas, Matthias Zschunke, Michael R. Alvers, Dirk Weissenborn, Anastasia Krithara, Sergios Petridis, Dimitris Polychronopoulos, et al. An overview of the BioASQ large-scale biomedical semantic indexing and question answering competition. *BMC Bioinformatics*, 16(1):138, 2015. doi: 10.1186/s12859-015-0564-6.

A. Disponibilidade de código, datos e modelos

O código fonte, as coleccións empregadas, o *benchmark*, as predicións finais e os scripts de reprodución están dispoñibles no repositorio de GitHub [braisglopez/medical-qa-sft](https://github.com/braisglopez/medical-qa-sft).

Os adaptadores LoRA obtidos mediante QLoRA están dispoñibles na organización *citiusLTL* de Hugging Face:

- Gemma 3 4B-IT + Drugs-SFT;
- Gemma 3 4B-IT + WHO-SFT;
- Gemma 3 4B-IT + Drugs+WHO-SFT;
- Qwen2.5 0.5B-Instruct + Drugs-SFT;
- Qwen2.5 0.5B-Instruct + WHO-SFT.

B. Instrución completa empregada na xeración de WHO-SFT

Este anexo reproduce literalmente as dúas mensaxes que compoñen a instrución empregada para xerar pares de preguntas e respostas a partir de cada fragmento das *WHO Fact Sheets*. Na mensaxe de usuario, {title}, {url} e as expresións asociadas a **chunk** substitúense polos valores correspondentes ao documento e ao fragmento que se está a procesar. A versión executable pode consultarse no script `generate_who_qa.py` do repositorio de código. As liñas longas axústanse visualmente ao ancho da páxina sen modificar o contido da instrución.

B.1. Instrución de sistema

```
You extract high-quality medical question-answer training examples from WHO source text.
Use only the provided source text. Do not add facts, numbers, dates, definitions,
recommendations, or clinical advice that are not supported by the source text.
Preserve the exact population, denominator, timeframe, comparison, and condition
from the source text. Never broaden a statistic or statement. If the source
refers to a specific group, condition, region, age range, or timeframe, keep
that same scope in the question and answer.

Return valid JSON only, with this exact shape:
{
  "items": [
    {
      "question": "A natural medical or public-health question in English",
      "answer_text": "A clear, standalone answer in English grounded in the source text",
      "category": "definition|symptoms|risk_factors|causes|transmission|diagnosis|treatment|prevention|complications|burden|public_health|other",
      "evidence": "A short phrase or sentence from the source text that supports the answer"
    }
  ]
}

Do not include markdown, bullets, numbering, citations, URLs, comments, or reasoning.
```

B.2. Instrución de usuario

```
/no_think

Generate all distinct medical or public-health question-answer pairs supported by this WHO topic chunk.
There is no fixed number of items. Return as many useful, non-duplicated items as the text supports.

Requirements:
- Questions must be useful for supervised fine-tuning of a medical QA model.
- Prefer clinically useful medical or public-health questions over isolated trivia.
- Each item must ask about a distinct fact, not a rewording of another question.
- Include only questions answerable from this chunk.
- Preserve the exact denominator, population, time period, comparison, and disease scope from the source text.
- Never broaden a statistic. If the source refers to a specific group, condition, region, age range, or timeframe, keep that same scope in the question and answer.
- Prefer definition, symptoms, risk factors, causes, transmission, diagnosis, treatment, prevention, complications, public-health burden, and WHO actions when the chunk supports them.
- Generate statistical questions only when the statistic is medically or public-health relevant, and preserve the exact denominator and year.
```

- If a question asks for a percentage, rate, proportion, count, or number, name the measured group explicitly in the question.
- Do not create questions from incomplete lead-in sentences ending with ":" unless the answer is fully present in the chunk.
- Avoid vague broad questions such as "What are some potential problems..." when the source supports one specific complication; ask the specific question instead.
- Skip purely administrative, navigation, copyright, citation, or webpage-related content.
- Answers must be clear, factual, standalone, and usually 1 to 3 sentences.
- Do not mention "the source text", "the chunk", or "the article".
- If the chunk has no medical or public-health facts, return {"items": []}.

Topic title: {title}

Topic URL: {url}

Chunk paragraphs: {chunk["paragraph_start"]}--{chunk["paragraph_end"]}

Source text:

{chunk["text"]}